# Проблема холодного старта объекта на примере рекомендательной системы фильмов

Самойлов Павел, Б05-404

## Постановка задачи

Имеются данные о взаимодействиях пользователей с объектами системы — фильмами (оценки), а также информация о фильмах: жанр, описание, постер, трейлер. Регулярно выходят новые фильмы, которые никто из пользователей ещё не смотрел и не оценивал.

Требуется построить модель, которая на основании перечисленной выше информации будет рекомендовать новые фильмы тем пользователям, которым они будут интересны. Необходимо, помимо прочего, продумать архитектуру модели, принцип её работы, процесс обучения, способ разбиения данных и методику оценивания рекомендаций, выданных разработанной моделью.

Основные ограничения задачи — ограниченные вычислительные ресурсы, недоступность данных о взаимодействии пользователей с "новыми" фильмами при тестовых запусках, неясность интерпретации отсутствия оценки фильма пользователем.

## Данные и критерии

### Датасеты

- M$^3$L-10M — 9.4 миллионов оценок, 69878 пользователей, 9031 фильм. Содержит данные об оценках, а также жанрах фильма, его описании, постере, трейлере. Подходящий по масштабу датасет: не слишком большой, чтобы тратить большое количество времени и вычислительных ресурсов на обучение и тесты, и не слишком маленький, чтобы проводить достаточно полные исследования. Является расширением популярного датасета MovieLens 10M, не содержащего данных о постере и трейлере, но с оговоркой: взяты только те фильмы, для которых эти данные нашлись.

- M$^3$L-20M — 18.8 миллионов оценок, 138493 пользователя, 19009 фильмов. Относительно большой набор, подходит для получения более точных и обширных результатов у моделей, показавших хорошие результаты на M$^3$L-10M. Является расширением популярного датасета MovieLens 20M с теми же оговорками, что и для M$^3$L-10.

Датасеты разбиваются по схеме train-valid-test в соотношении 80-10-10 (см. ниже).

### Оценка качества решения

Для оценки качества решения предлагаю использовать следующие метрики:

- NDCG@10 — популярная в сфере исследований рекомендательных систем метрика. Оценивает, как высоко в списке рекомендаций пользователя находятся те фильмы, которые он оценил лучше. Используем оценки как градуированную релевантность.

- Pairwise Accuracy — показывает, как часто модель правильно определяет, какой из двух фильмов пользователь оценил выше (в нашем случае различие оценки должно быть не менее 1 балла, см. ниже).

- Recall@10 — метрика для дополнительной проверки релевантности рекомендаций. Порог положительной оценки — 4/5 и выше.

# Обзор решений

### Maciej Kula — Metadata Embeddings for User and Item Cold-start Recommendations (2015)

Основополагающая в рамках задачи статья. Автор предлагает использовать гибридную модель LightFM: объекты (пользователи и фильмы) представлены не как обучаемые векторы, а как суммы обучаемых векторов их признаков, что даёт возможность переносить принцип работы модели на новые объекты, не имеющие данных об оценках, используя лишь присущие им характеристики и признаки.

Работа решает одну из главных частей нашей задачи — предлагает вышеописанный принцип, по которому можно использовать признаки свежих объектов для рекомендации их пользователям.

Статья является релевантной, так как обозревает решение конкретно нашей задачи, использует схожие принципы проведения эксперимента. На октябрь 2026 года — 235 цитирований, в том числе десятки цитирований в статьях 2026 года (Semantic Scholar), что подтверждает актуальность идей, описанных в работе.

Ограничения:

- Модель опирается на заранее известный набор признаков, и новый признак не получит свой обученный вектор;
- В эксперименте оценки бинаризируются, вследствие чего теряется возможность предсказать точную оценку для новых объектов;
- Исследование проведено на более простых по структуре датасетах — переносимость результатов на более новые мультимодальные датасеты с другими структурами признаков нужно проверять отдельно.

### Yi-Fan Chen et al. — Item Cold-Start Recommendation with Personalized Feature Selection (2020)

Авторы рассматривают проблему того, что каждый пользователь ценит определённые признаки объекта и обращает мало внимания на другие. В связи с чем предлагают два варианта решения:

- U-PFS: каждому пользователю ставится в соответствие его личный вектор весов признаков.
- G-PFS: вектор весов признаков выдаётся не каждому пользователю, а группе пользователей с похожими вкусами.

Рассматриваются и две функции потерь: квадратичная и BPR (байесовское персонализированное ранжирование). Вторая даёт обучение на попарных предпочтениях, что "продвигает" более релевантные объекты.

Результаты показывают, что максимально персонализированные рекомендации не всегда являются лучшими; в некоторых ситуациях (например, при работе с датасетом Amazon) более быстрый и экономичный G-PFS оказывается эффективнее.

Работа решает часть задачи, посвящённую персонализации используемых данных — какие признаки важны для конкретного пользователя или группы пользователей (то есть как распределять веса в каждом случае), и помогает ли это в задаче холодного старта вообще.

Статья релевантна относительно нашей задачи. Она освещает очень важную проблему персонализации рекомендаций, описанную выше. Процессы экспериментальной проверки во многом схожи (разбиение данных train-valid-test: 80-10-10), рассматривается задача Item Cold-Start. Работа являяется расширением более ранней статьи "Learning to Select User-Specific Features for Top-N Recommendation of New Items" (2019).

Ограничения:

- Исследование проводилось на датасетах научных публикаций и товаров (CiteULike и Amazon Sports & Outdoors), на датасетах фильмов — нет.
- Эксперимент опирается только на текстовые признаки объектов.
- Бинаризация оценки объектов пользователем.
- Вычислительная сложность метода U-PFS на датасете Amazon довольно велика.

**Yashar Deldjoo et al. — Movie genome: alleviating new item cold start in movie recommendation (2019)**

Тема работы очень сильно перекликается с нашей задачей. Авторы вводят концепт "Movie Genome" — цельное представление фильма, полученное на основе текстовых, визуальных и аудио-признаков из трейлера и описания. Полученные данные разных типов объединяются при помощи разработанного авторами ранее метода CCA (Canonical Correlation Analysis). Он заключается в нахождении линейных преобразований пространств двух признаков, после которых соответствующие представления имеют наибольшую корреляцию, и объединении этих новых представлений. Затем предлагается двухэтапная гибридная схема CFeCBF (Collaborative-Filtering-enriched Content-Based Filtering). На первом этапе коллаборативная модель обучается на фильмах с взаимодействиями; на втором с помощью её результатов обучаются веса признаков фильма, что улучшает рекомендации модели. Как результат, гибридная система в большинстве случаев показывала лучший результат по сравнению со стандартной мультимодальной контентной моделью по метрикам NDCG и MAP.

Работа решает проблему рекомендации фильмов на основе не только текстовых, но и визуальных и звуковых данных, а также задачу объединения этих данных разных типов (модальностей) и использование их в сложной схеме обучения.

Статья является релевантной. Она важна для нашего случая, так как работа хорошо дополняет остальные, рассмотренные нами, которые не брали в расчёт какие-либо данные, кроме текстовых. Качественно и детально проведена оценка результатов. Рассмотрена не только задача холодного старта, но и переход в "тёплое" состояние, когда фильм набирает первые взаимодействия с пользователями. Статья имеет 95 цитирований (Semantic Scholar), в том числе за 2026 и 2025 годы, что указывает на актуальность полученных в ней результатов для дальнейших исследований.

Ограничения:

- Зависимость от количества признаков. При малом их количестве рекомендации становятся менее разнообразными, при неполноте некоторых данных результаты модели сильно ухудшаются. При большом же количестве признаков коллаборативная модель может не справляться с обучением весов.
- Вычислительные ресурсы метода повышены из-за использования мультимодальных дескрипторов (видео- и аудиоряд).
- CFeCBF зависит от качества изначальной коллаборативной модели; если взаимодей-

ствий мало, результат может сильно ухудшиться. Также обучение весов происходит только для признаков, встречавшихся у фильмов с данными о взаимодействиях.

# Подход к решению

## Архитектура

Беря хорошего понемногу из каждой вышеуказанной работы, я предлагаю гибридную мультимодальную рекомендательную модель с персонализированным ранжированием.

Входные данные и их обработка:

- структурированные признаки (жанры) — слои эмбеддингов;
- текстовые описания, мультимедиа (изображения, звуки и т.д.) — векторы уже готовы.

Полученные векторы приводим к одной размерности при помощи отдельных обучаемых линейных слоёв (матриц линейных проекций). На этом этапе каждая модальность всё ещё представлена отдельным вектором — мы лишь приводим их к общему пространству, чтобы впоследствии иметь возможность объединить их.

Также обучается представление пользователя: каждому пользователю соответствует латентный вектор предпочтений, формируемый на основе его истории взаимодействий. Затем для каждой пары "пользователь – фильм" с помощью MLP (небольшой полносвязной сети) вычисляется важность каждой доступной модальности для данного пользователя. Полученные значения нормируются при помощи softmax, образуя веса модальностей. Если какая-либо модальность отсутствует у фильма, она не учитывается при расчёте весов.

В итоге получаем единое представление фильма, объединяющее все доступные модальности с учётом предпочтений пользователя.

Полученные представления фильма и пользователя скалярно перемножаются; результаты ранжируются, в соответствии с чем ранжируется и список рекомендаций.

## Способ обучения

1. Разделяем все данные на три группы: взаимодействие пользователей и фильмов, категориальные признаки фильмов и признаки фильмов из текста, аудио, изображений и видео. Для отдельного фильма для каждой модальности вводим индикатор её доступности. Также разбиваем данные на train-valid-test в соотношении (по количеству фильмов) 80-10-10. Исключаем из обучения пользователей, у которых нет ни одной пары оценённых фильмов.
2. Для каждой модальности извлекаем признаки. Обучаем матрицы линейных проекций, а также (для метаданных) слои эмбеддингов.
3. Формируем обучающие примеры на имеющихся данных о взамимодействиях. Для каждого пользователя $u$ случайным образом выбираем два фильма $i$ и $j$, которые он оценил, и притом оценки отличаются не меньше, чем на 1.0 балла. Если он оценил первый фильм лучше, чем второй, записываем эти данные как тройку $(u,i,j)$; иначе — $(u,j,i)$. Ограничиваем количество таких троек на одного пользователя, чтобы обучение не скосилось в сторону наиболее активных пользователей.
4. Рассматриваем пару "пользователь – фильм". С помощью MLP для каждого доступного источника информации вычисляем его важность для этого пользователя — вес, который затем нормируем через softmax. Объединяем признаки, рассчитываем оценки как скалярные произведения обучаемого вектора пользователя и вектора фильма: $s(u,i) = p_u^\top q_{ui}$. Хороший исход — когда $s(u,i) > s(u,j)$.

5. В качестве функции потерь используем принцип BPR, только для случая, когда для обоих фильмов имеется взаимодействие (оценка).
6. Оптимизируем параметры, используя AdamW. Он будет обновлять слои эмбеддингов, пользовательские векторы, матрицы линейной проекции и параметры MLP.
7. После эпохи обучения (п. 1–6) через NDCG@10 проверяем модель на valid-выборке; дополнительно можно проверять Recall@10. Если качество не улучшается в течение нескольких эпох, останавливаем обучение и берём лучшую достигнутую версию.
8. Для нового фильма (на этапе теста) строим представление только на доступных данных (без данных о взаимодействии то есть), ранжируем на основе полученных результатов.

Основные design choices описаны внутри этого и предыдущего пунктов.

# План проверки

- Берём датасет $M^3$L-10M. Составляем статистику доступности по каждому типу данных, чтобы оценить применимость мультимодальной системы в том или ином виде.
- Разбиваем данные согласно пункту 1 в "Способе обучения"; далее проводим обучение согласно этому разделую

Рассмотрим три разлиных baseline:

1. Неперсонализированная модель на метаданных: рассчитываем оценку нового фильма, основываясь на его жанрах и средних оценках фильмов этих жанров в train. Для редких жанров, чтобы избежать "выбросов используем сглаживание к глобальному среднему значению. Данный baseline — проверка модели, построенной на метаданных без учёта личных предпочтений пользователя в плане типа данных.

2. Стандартная контентная модель: обучаем вектор пользователя с вычислением весов признаков для него; затем скалярно перемножаем его с вектором нового фильма и смотрим на результат. Этот baseline — проверка модели, идентичной нашей, но без использования какой-либо информации о фильме, кроме непосредственно метаданных и, в случае обучения, оценок.

3. Feature-based модель: используем все признаки фильмов, но объединяем все модальности простым алгоритмом (например, конкатенацией), далее действуем как по нашему алгоритму обучения. Данный baseline даст понимание, даёт ли положительный эффект наш этап с вычислением весов модальностей с помощью MLP или же только усложняет модель.

## Основные эксперименты и абляции

1. Только метаданные: проверяем полезность базовых категориальных данных.
2. Только описания: проверяем пользу описаний фильмов.
3. Все данные, но без распределения весов: проверяем пользу мультимодальности без персонализации.
4. Проверяем нашу оригинальную модель.

Абляции: стоит провести эксперименты, в которых по очереди не будут учитываться каждая из модальностей, а также эксперимент, где не будут учитываться сразу признаки из видео- и аудиорядов.

Дополнительно: провести эксперименты, исследующие влияние на результаты:

- размера истории пользователя;
- неполноты модальностей;
- размера латентного пространства;

- порога разницы оценок фильмов, образующих тройки для обучения.

## Вычислительная стоимость и реализация

За счёт использования датасета с уже расшифрованными модальностями трейлеров и постеров наша оперативная память не тратится на этот процесс. Если же всё же используем свои собственные энкодеры, то не обучаем их, а замораживаем на стоковых параметрах.

Непосредственно процесс обучения рекомендательной части тратит не самое большое количество ресурсов и времени; тестовый запуск на наборе MovieLens 10M показал, что даже старый ноутбук справляется с обучением в среднем за 5 минут, и ему хватает 8 ГБ оперативной памяти для этого. Однако стоит всё же фиксировать длительности обработки данных, обучения и вычисления результата, а также количество затрачиваемой памяти.

## Устойчивость и границы применимости

Следует проверить модель на работоспособность в следующих ситуациях:

- отсутствие модальности у фильма;
- неизвестные представители категорий;
- неактивные пользователи с малым количеством оценок;
- переобучение на фильмах с очень большим количеством оценок.

Наше решение, конечно же, всё же имеет ограничения:

- Качество результата зависит от наличия и полноты модальностей, также неизвестно, как скажется на нём добавление большого числа новых представителей в категориях метаданных;
- Качество оценки сильно ограничено тем, что мы не знаем точно, как оптимально интерпретировать отсутствие оценок.

## Если метод хуже baseline...

1. Проверяем правильность подготовки данных;
2. Проверяем каждую из модальностей на предмет ухудшения результата;
3. Проверяем, не скошена ли модель в сторону одной из модальностей;
4. Проверяем, честно ли работает baseline;
5. Пробуем упростить работу MLP или умменьшить размерность латентного пространства;
6. Пробуем проводить эксперимент на других сидах разбиения.

Если не помогает — упрощаем мультимодальность и/или персонализацию модели.

Можно рассмотреть вариант использования временных меток оценок для конкретного пользователя — построить "эволюцию" его предпочтений, или попробовать извлекать информацию об актёрском составе и режиссёре по ID из TMDb (или же использовать датасет HetRec 2011, в котором эти данные уже есть). Но это уже выходит за рамки моего решения.